

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ ІМЕНІ ІГОРЯ СІКОРСЬКОГО»
КАФЕДРА ІНФОРМАТИКИ ТА ПРОГРАМНОЇ ІНЖЕНЕРІЇ

КУРСОВА РОБОТА

з дисципліни «Аналіз даних в інформаційних системах»

на тему: «Аналіз впливу атмосферних викидів на поширеність
онкозахворювань в регіонах України»

Студента 2 курсу ІП-33 групи

Спеціальності: 121

«Інженерія програмного забезпечення»

Корольчука Олександра Сергійовича

«ПРИЙНЯВ» з оцінкою

доц. Ліхоузова Т.А. / доц. Олійник Ю.О.

Підпис

Дата

Київ - 2025 рік

Національний технічний університет України “КПІ ім. Ігоря Сікорського”

Кафедра інформатики та програмної інженерії

Дисципліна Аналіз даних в інформаційно-управляючих системах

Спеціальність 121 "Інженерія програмного забезпечення"

Курс 2 Група ІІІ-33

Семестр 4

ЗАВДАННЯ

на курсову роботу студента

Корольчука Олександра Сергійовича

1.Тема роботи Аналіз впливу атмосферних викидів на поширеність онкозахворювань в регіонах України

2.Строк здачі студентом закінченої роботи 28.05.2025

3. Вхідні дані до роботи методичні вказівки до курсової роботи, обрані дані з сайту
http://www.ncru.inf.ua/publications/BULL_23/PDF/BULL_23.pdf (25 сторінка)
http://www.ncru.inf.ua/publications/BULL_22/PDF/BULL_22.pdf (17 сторінка)
<https://stat.gov.ua/uk/datasets/vykydy-zabrudnyuyuchykh-rechovyn-i-parnykovykh-haziv-v-atmosferne-povitrya>
<https://stat.gov.ua/uk/datasets/chyselnist-ta-pryrodnyy-rukhn-naselennya-0>

4.Зміст розрахунково-пояснювальної записки (перелік питань, які підлягають розробці)

1.Постановка задачі

2.Аналіз предметної області

3.Розробка сховища даних

4.Інтелектуальний аналіз даних

5.Перелік графічного матеріалу (з точним зазначенням обов’язкових креслень)

6.Дата видачі завдання 25.03.2025

КАЛЕНДАРНИЙ ПЛАН

№ п/п	Назва етапів курсової роботи	Термін виконання етапів роботи	Підписи керівника, студента
1.	Отримання теми курсової роботи	25.03.2025	
2.	Визначення зовнішніх джерел даних	04.04.2025	
3.	Пошук та вивчення літератури з питань курсової роботи	10.04.2025	
4.	Розробка моделі сховища даних	18.04.20205	
4.	Розробка ETL процесів	25.04.2025	
5.	Обґрунтування методів інтелектуального аналізу даних	05.05.2025	
6.	Застосування та порівняння ефективності методів інтелектуального аналізу даних	10.05.2025	
7.	Підготовка пояснювальної записки	20.05.2025	
8.	Здача курсової роботи на перевірку	28.05.2025	
9.	Захист курсової роботи	29.05.2025	

Студент

(підпис)

Корольчук О.С.

(прізвище, ім'я, по батькові)

Керівник

(підпис)

доц. Ліхоузова Т.А

(прізвище, ім'я, по батькові)

Керівник

(підпис)

доц. Олійник Ю.О.

(прізвище, ім'я, по батькові)

АНОТАЦІЯ

Пояснювальна записка до курсової роботи: 47 сторінок, 27 рисунки, 5 таблиць, 5 посилань.

Об'єкт дослідження:

Предмет дослідження: моделі та методи аналізу.

Мета роботи: Аналіз впливу атмосферних викидів на поширеність онкозахворювань в регіонах України.

Задачі: проектування та реалізація сховища даних та ETL процесів, а також реалізація програмного забезпечення для отримання даних зі сховища та їх подальшого аналізу та моделювання.

Дана курсова робота включає в себе: опис проектування, створення та заповнення сховища даних за даною задачею за допомогою фізичної моделі бази даних; опис створення програмного забезпечення для інтелектуального аналізу даних, їх графічного відображення та класифікації за допомогою різних моделей; оцінку якості та порівняльний аналіз побудованих моделей; рекомендації по використанню моделей.

Результати роботи можуть бути корисними для дослідження та виявлення впливу атмосферних викидів на захворювання раком та смерті від цієї хвороби в регіонах України.

СХОВИЩЕ ДАНИХ, МОДЕЛЬ ПРОГНОЗУВАННЯ, ІНТЕЛЕКТУАЛЬНИЙ АНАЛІЗ ДАНИХ, ФІЗИЧНА МОДЕЛЬ БАЗИ ДАНИХ, ELT ПРОЦЕСИ, МОДЕЛЬ ЛІНІЙНОЇ РЕГРЕСІЇ, МОДЕЛЬ ПОЛІНОМІАЛЬНОЇ ЛІНІЙНОЇ РЕГРЕСІЇ, КЛАСТЕРИЗАЦІЯ

ЗМІСТ

ВСТУП.....	7
1.ПОСТАНОВКА ЗАДАЧІ.....	9
2.АНАЛІЗ ПРЕДМЕТНОЇ ОБЛАСТІ.....	10
3.РОЗРОБКА СХОВИЩА ДАНИХ.....	12
3.1 Розробка моделі сховища даних	12
3.2 Редагування та завантаження даних.....	19
3.3 Розподіл даних.....	26
4.ІНТЕЛЕКТУАЛЬНИЙ АНАЛІЗ ДАНИХ.....	29
4.1 Обґрунтування вибору методів інтелектуального аналізу даних	29
4.2 Аналіз отриманих результатів дослідження кореляції між ознаками	30
4.3 Аналіз отриманих результатів кластеризації.....	36
4.4 Аналіз моделі Linear Regression.....	38
4.5 Аналіз поліноміальної моделі лінійної регресії	40
ВИСНОВКИ.....	42
ПЕРЕЛІК ПОСИЛАНЬ.....	45
ДОДАТОК А ТЕКСТИ ПРОГРАМНОГО КОДУ	46

ВСТУП

За офіційною статистикою, кожен п'ятий українець страждає від онкологічних захворювань. В Україні щогодини реєструють 18 нових випадків раку. Люди щодня роблять тисячі вдихів і споживають близько 10 000 літрів повітря на день. Разом з необхідним киснем організм отримує також значні дози забруднювачів, які можуть бути присутніми у різних концентраціях. Забруднювачем повітря вважається будь-яка речовина, що не осідає на поверхню Землі під дією сили тяжіння і може завдавати шкоди здоров'ю людей, екосистемі або всій планеті. Деякі забруднювачі, такі як діоксид вуглецю та метан сприяють зміні клімату та безпосередньо впливають на здоров'я людини.[1][2]

Сьогодні забруднення повітря у світі визнано найбільшою екологічною загрозою для цивілізації. У 2016 році 90% населення землі проживало в небезпечних місцях, які щодо якості дихання не відповідали вимогам Всесвітньої організації охорони здоров'я (ВООЗ). Внесок кожної країни у загальне забруднення атмосферного повітря у світі різний. Країною з найвищим рівнем забрудненості вважається Монголія. Для порівняння – Фінляндія посідає 109 місце з дуже невеликим негативним впливом, а Україна – 46 місце.[2]

Тривалий вплив забрудненого повітря підвищує ризик смерті від ішемічної хвороби серця на 24%, від раку легені на 28%, хронічної обструктивної хвороби й інфекції легень на 43%, інсульту на 25%. Ще у 1950 році англійські епідеміологи Річард Долл і Остін Хілл назвали дві можливі причини збільшення випадків раку легені у XX столітті. Вони вважали, що такими можуть бути загальне забруднення атмосферного повітря автомобільними вихлопами, пилом асфальтових доріг, заводів, промислових підприємств і димом від горіння вугілля. Згодом вчені довели роль куріння як домінуючої причини раку легені і, можливо, на наступні 70 років відвернули увагу від впливу забруднення повітря як ще однієї головної причини раку. Сьогодні відомо, що крім раку легені, атмосферні канцерогени відповідають за розвиток раку грудної залози у жінок (11,6%), передміхурової залози (7,1%), товстої кишки (6,1%), шлунка (8,2%), печінки

(8,2%), а також раку носоглотки, гортані, стравоходу, підшлункової залози, нирок, сечового міхура, шийки матки та мієлоїдного лейкозу.[2]

Таким чином, постає мета аналізу впливу атмосферних викидів на захворювання на рак по регіонах України та побудова моделей для прогнозування залежності даних ознак. У рамках даної курсової роботи було зібрано дані, їхнє попереднє очищення, приведення до одних типів, вирішено проблему з пропущеними даними, розроблено сховище даних забруднення повітря та захворюваності на рак. В ролі системи керування сховищем даних для даної роботи буде виступати PostgreSQL, а мова, з допомогою якої проводитиметься аналіз – Python3

1. ПОСТАНОВКА ЗАДАЧІ

Під час виконання курсової роботи необхідно виконати наступні завдання:

Створення сховище даних типу “зірка”. Структура курсової роботи узгоджена з керівником. Сховище даних повинне містити щонайменше 3 таблиці вимірів та таблицю фактів. Створити ETL процеси для завантаження даних до сховища, їх отримання зі самого сховища за допомогою запитів. Реалізувати спроектоване сховище даних за допомогою СУБД PostgreSQL.

Створення застосунку, що отримує вибірку даних зі створеного сховища, графічно відображає дані, проводить їх інтелектуальний аналіз для отримання результатів про залежність ознак та передбачення за допомогою різних моделей прогнозування.

Провести аналіз на корелювання певних ознак, порівняти результати і зробити відповідні висновки.

Для аналізу даних використати такі моделі прогнозування як Linear regression, Поліноміальна регресія з відповідним визначенням її кращого ступеня та Random forest regression.

Розділити дані на навчальну та тестові вибірки для побудови моделей прогнозування.

Перевірити моделі відповідними метриками та провести аналіз отриманих результатів, обрати найоптимальніший модель.

Використати мову програмування Python3 для реалізації застосунку.

Курсовий проект здати до дедлайну 28.05.2025 та виконати у єдиному стилі написання коду.

2.АНАЛІЗ ПРЕДМЕТНОЇ ОБЛАСТІ

Одними з найпоширеніших хвороб серед українців є онкологічні захворювання, такі як рак легенів, молочної залози та товстого кишечника. Щодня ми страждаємо від атмосферних викидів зі стаціонарних та пересувних джерел. Мешканці індустріальних регіонів демонструють різну здатність жити в біологічно агресивному та небезпечному середовищі. Але адаптація населення промислово розвинених районів до постійної наявності подразнюючих речовин у повітрі, яким вони дихають, не дозволяє їм уникнути хронічних захворювань, у тому числі раку. Україна посідає 46 місце у світі у рейтингу забрудненості атмосферного повітря, що є доволі негативним результатом. [2]

Джерела атмосферного забруднення можна поділити на дві категорії – стаціонарні та пересувні. До стаціонарних джерел забруднення відносяться підприємства, цехи, агрегати, установки або інші нерухомі об'єкти, що зберігають свої просторові координати протягом певного часу і здійснюють викиди забруднюючих речовин в атмосферу та/або скиди забруднюючих речовин у водні об'єкти.[4]. Пересувні джерела забруднення – це транспортні засоби, рух яких супроводжується викидом в атмосферу забруднюючих речовин.[5].

Дані про онкологічні захворювання класифікуються наступними метриками: кількість смертей, кількість захворювань, грубий показник смертності, грубий показник захворюваності. Грубі показники визначаються у співвідношенні кількості на 100 тис. осіб населення.

Важливо виявити та дослідити закономірності між такими ознаками, як пересувні та стаціонарні джерела, кількість смертей та захворювань, грубі показники смертності та захворюваності.

У програмному забезпеченні буде реалізовано наступну функціональність, що включає в себе:

- проектування сховища даних;
- створення ETL процесів для завантаження і оновлення даних;
- створення навчальної та тренувальної вибірки даних з сховища;

- аналіз взаємозв'язку між ознаками;
- побудову декількох моделей прогнозування даних;
- графічне відображення отриманих результатів та їх аналіз.

3. РОЗРОБКА СХОВИЩА ДАНИХ

3.1 Розробка моделі сховища даних

Для виконання курсової роботи було обрано 4 джерела відкритих даних з наступних сайтів:

- Інформація про онкозахворювання в Україні по регіонах за 2020 рік:

http://www.ncru.inf.ua/publications/BULL_22/PDF/BULL_22.pdf

- Інформація про онкозахворювання в Україні по регіонах за 2021 рік:

http://www.ncru.inf.ua/publications/BULL_23/PDF/BULL_23.pdf

- Інформація про викиди забруднюючих речовин в Україні по регіонах за 2020 та 2021 рік:

[https://stat.gov.ua/uk/explorer?urn=SSSU:DF_POLLUTANTS_GASES_EMISSIONS\(12.0.0\)](https://stat.gov.ua/uk/explorer?urn=SSSU:DF_POLLUTANTS_GASES_EMISSIONS(12.0.0))

- Інформація про населення в Україні по регіонах за 2020 та 2021 рік:

https://stat.gov.ua/uk/explorer?urn=SSSU%3ADF_POPULATION_STRUCTURE%287.0.0%29&filter=PNMI_04.%2A.%2A.%2A.%2A.%2A

На основі детального опису та проведеного аналізу предметної області було розроблено наступну модель сховища даних про онкозахворювання та викидати забруднюючих речовин в атмосферне повітря за типом “зірка” (рис. 3.1)




Рисунок 3.1 – Спроектвана модель сховища за типом “зірка”

У моделі сховища за типом “зірка” спроектовано таблицю фактів “cancer_analysis”, що відповідає за самі дані, призначені для аналізу, та три таблиці вимірів, призначені для зберігання інформації про якісні ознаки. Нижче наведено опис полів кожної таблиці сховища даних інформації про онкозахворювання та викиди забруднюючих речовин в атмосферне повітря. (таблиці 3.1 – 3.4)

Таблиця 3.1 – таблиця виміру регіонів dim_region_data

Назва поля	Опис поля
region_id	Унікальний ідентифікатор
region_name	Назва територіального розрізу (регіону)

Таблиця 3.2 – таблиця виміру викидів забруднюючих речовин в атмосферне повітря dim_pollution

Назва поля	Опис поля
pollution_id	Унікальний ідентифікатор
source_name	Джерело забруднення
pollutant_type_name	Назва забруднювача
category_name	Категорія джерела забруднення

Таблиця 3.3 – Таблиця виміру років dim_year

Назва поля	Опис поля
year_id	Унікальний ідентифікатор
year	Рік, за який наведені дані

Таблиця 3.4 – Таблиця співставлення фактів про захворювання та фактів про викиди забруднюючих речовин в атмосферне повітря cancer_analysis

Назва поля	Опис поля
id	Унікальний ідентифікатор
region_info	Зовнішній ключ на таблицю dim_region_data
population_count	Кількість населення
year_info	Зовнішній ключ на таблицю dim_year
death_cases_count	Кількість випадків смертей від раку
disease_cases_count	Кількість випадків захворювання на рак
crude_death_rate	Грубий показник смертності від раку (на 100 тис. осіб)
crude_disease_rate	Грубий показник захворюваності на рак (на 100 тис. осіб)
pollution_info	Зовнішній ключ на таблицю dim_pollution
pollution_count	Кількість викидів у атмосферне повітря

Також перед створенням main зони для зберігання чистих даних було створено stage зону. Відповідно засобами СУБД створено дві схеми: stage та main. У таблиці 3.5 наведено опис полів вхідних даних.

population.csv	id	Унікальний ідентифікатор
	indicator	Назва метрики даних
	region_name	Назва регіону
	periodicity	Період
	population_count	Кількість населення
	year	Рік
cancer_disease_and_death.csv	id	Унікальний ідентифікатор
	region_name	Назва регіону
	disease_case_count	Кількість випадків захворювання на рак
	incidence_rate	Грубий показник захворюваності на 100 тис. населення
	death_case_count	Кількість випадків смертей від раку
	death_rate	Грубий показник смертності на 100 тис. населення
	year	Рік

pollution_data.csv	id	Унікальний ідентифікатор
	indicator	Назва метрики даних
	region_name	Назва регіону
	source_of_pollution	Джерело забруднення
	pollutant_type_name	Вид забруднюючої речовини

На основі спроектованої моделі було створено stage та main зону для зберігання наших даних, що включає три таблиці у stage зоні, та 3 таблиці вимірів і одну таблицю фактів у main зоні. Нижче наведені відповідні скрипти, використовуючи PostgreSQL версії 16.

```
CREATE SCHEMA stage;
CREATE SCHEMA main;
CREATE TABLE IF NOT EXISTS stage.pollution_data (
    id SERIAL PRIMARY KEY,
    indicator VARCHAR(255),
    region_name VARCHAR(255),
    source_of_pollution VARCHAR(255),
    pollutant_type_name VARCHAR(255),
    source_category_name VARCHAR(255),
    periodicity VARCHAR(255),
    pollution_count BIGINT,
    year INTEGER
);
```

```
CREATE TABLE IF NOT EXISTS stage.population (
```



```
id SERIAL PRIMARY KEY,  
indicator VARCHAR(255),  
region_name VARCHAR(255),  
periodicity VARCHAR(255),  
population_count INTEGER,  
year INTEGER  
);
```

```
CREATE TABLE IF NOT EXISTS stage.cancer_disease_and_death (  
id SERIAL PRIMARY KEY,  
region_name VARCHAR(255),  
disease_case_count INTEGER,  
incidence_rate FLOAT,  
death_case_count INTEGER,  
death_rate FLOAT,  
year INT  
);
```

```
CREATE TABLE IF NOT EXISTS main.dim_region_data (  
region_id SERIAL PRIMARY KEY,  
region_name VARCHAR(255) NOT NULL  
);
```

```
CREATE TABLE IF NOT EXISTS main.dim_pollution (  
pollution_id SERIAL PRIMARY KEY,  
source_name VARCHAR(255) NOT NULL,  
category_name VARCHAR(255) NOT NULL,  
pollutant_type_name VARCHAR(255) NOT NULL  
);
```

```
CREATE TABLE IF NOT EXISTS main.dim_year (
    year_id SERIAL PRIMARY KEY,
    year INTEGER NOT NULL
);
```

```
CREATE TABLE IF NOT EXISTS main.cancer_analysis (
    id SERIAL PRIMARY KEY,
    region_info      INTEGER      NOT      NULL      REFERENCES
main.dim_region_data(region_id),
    population_count INTEGER NOT NULL,
    year_info INTEGER NOT NULL REFERENCES main.dim_year(year_id),
    death_cases_count INTEGER NOT NULL,
    disease_cases_count INTEGER NOT NULL,
    crude_death_rate NUMERIC(5, 2) NOT NULL,
    crude_disease_rate NUMERIC(5, 2) NOT NULL,
    pollution_info      INTEGER      NOT      NULL      REFERENCES
main.dim_pollution(pollution_id),
    pollution_count NUMERIC(5, 2) NOT NULL
);
```

```
ALTER TABLE main.cancer_analysis
```

```
ALTER COLUMN pollution_count TYPE NUMERIC(20, 2);
```

3.2 Редагування та завантаження даних

Спочатку підготуємо та завантажимо наші непідготовлені дані до stage зони нашого сховища. Для цього, з допомогою бібліотеки `sqlalchemy` створимо “движок” за допомогою методу `create_engine`, що слугуватиме нам зв’язком між нашим середовищем розробки та базою даних PostgreSQL.

Завантажуємо наші дані у датафрейм з допомогою бібліотеки `pandas`. Оскільки назви стовпців українською мовою, перейменовуватимемо відповідно

до назв стовпців у таблицях stage зони. Відповідно переходимо тепер до роботи з очищенням та перевіркою наших даних, заповненням пропусків, приведення до одних типів. Спочатку будемо працювати з даними про населення за 2020 та 2021 рік. Завантажуємо дані у дата фрейм, користуючись бібліотекою `pandas`. З ключових моментів, бачимо, що усі значення в рядках з інформацією про Крим та Севастополь є пропущеними. Приймаємо рішення, що ми виключимо ці записи з наших датафреймів, тому що в наших умовах не великої кількості даних, ми не можемо підібрати до прикладу середнє значення для кількості населення, оскільки це значно спотворить наші дані. Виконуємо перевірку, чи є присутні від’ємні значення і отримуємо позитивний результат – усі значення додатні, що задовольняє наші вимоги. Вивівши інформацію про типи даних стовпців, приведемо стовпець, який описує кількість населення до типу `int`.

Тепер перейдемо до підготовки даних про захворюваність та смертність від раку. Завантажуємо дані до датафрейму. Перевіряємо на пропущені значення і видаляємо рядки, які містять інформацію про Крим та м. Севастополь, спираючись на вже сформоване обґрунтування цьому рішенню. Серед важливих моментів помічаємо, що за 2020 та 2021 рік для Донецької та Луганської області відсутня інформація про грубі показники захворюваності та смертності на 100 тис. осіб. Але ми маємо інформацію про кількість населення, та кількість захворювань та смертей, що дає нам змогу самостійно порахувати ці показники за формулою “кількість випадків смертей (захворень для іншого показника)”, що множиться на 100 000, та ділиться на кількість населення. Відповідно таким чином отримуємо ці показники, та заповнюємо відповідні пропущені комірки. Приводимо показники до відповідних типів даних. Важливо зазначити, що при аналізі даних за 2021 рік, у інформації про Донецьку область були відсутні записи про кількість захворювань та смертей. Відповідно було прийнято рішення – взяти середнє по спорідненим індустриальним регіонам, такі як Дніпропетровська, Запорізька, Луганська та Харківська області.

Перейдемо до обробки даних про викиди забруднюючих речовин в атмосферне повітря. Тут значно більше щастить, тому що ці дані взяті з актуального державного сайту-ресурсу, що значно полегшує нам роботу. Знову ж таки, видаляємо записи про Крим та м. Севастополь, оскільки вони взагалі не містять ніяких даних. Ще під час завантаження даних з сайту, там було попередження, що інформація про кількість викидів зі стаціонарних джерел подана не в одиницях, а в тисячах. Відповідно помножимо кожне значення на 1000, щоб воно відповідало одиницям виміру викидів від пересувних джерел.

Наші дані очищені, підготовлені, збережені у нові .csv файли. Тепер можемо перейти до їхнього завантаження у stage зону. Будемо завантажувати дані по черзі – з нових csv-файлів завантажуюмо дані у датафрейм, користуючись бібліотекою pandas. Вбудований метод `.to_sql` дозволяє нам швидко завантажити дані у таблицю, всього лиш передаючи у якості параметрів наш відповідний датафрейм, назву схеми, назву таблиці, в яку завантажуюмо та передаємо наш “двиг” engine, який ми вже попередньо створили за допомогою бібліотеки sqlalchemy. На рисунках 3.2 – 3.4 зображено витяги записів з таблиць stage зони бази даних.

Query Query History

```
1 SELECT * FROM stage.cancer_disease_and_death
2 ORDER BY id ASC
```

Data Output Messages Notifications

Showing rows: 1 to 52

	id [PK] integer	region_name character varying (255)	disease_case_count integer	incidence_rate double precision	death_case_count integer	death_rate double precision	year integer
1	1	Україна	109409	291	56980	151.3	2020
2	2	Вінницька	4361	283.6	2466	160.3	2020
3	3	Волинська	2585	251.3	1573	152.9	2020
4	4	Дніпропетровська	9715	306.1	3937	124.1	2020
5	5	Донецька	4168	101.6	2235	54.5	2020
6	6	Житомирська	3106	256.9	1651	136.6	2020
7	7	Закарпатська	2294	183.4	1287	102.9	2020
8	8	Запорізька	5139	304.7	2801	166.1	2020
9	9	Івано-Франківська	3575	261.8	2135	156.4	2020
10	10	Київська	5184	292	2458	138.5	2020
11	11	Кіровоградська	3642	393	1885	203.4	2020
12	12	Луганська	1976	93	1077	50.7	2020
13	13	Львівська	7039	282.3	3271	131.2	2020
14	14	Миколаївська	3514	314	1457	130.2	2020
15	15	Одеська	5294	223.7	2083	88	2020

Total rows: 52 Query complete 00:00:00.521

Рисунок 3.2 – витяг записів з таблиці з інформацією про онкозахворювання

Query Query History

```
1 SELECT * FROM stage.pollution_data
2 ORDER BY id ASC
```

Data Output Messages Notifications

Showing rows: 1 to 104 Page No: 1 of 1

	id [PK] integer	indicator character varying (255)	region_name character varying (255)	source_of_pollution character varying (255)	pollutant_type_name character varying (255)	source_category_name character varying (255)	periodicity character varying (255)	pollution_count bigint	year integer
1	209	Кількість викидів забруднюючих речовин і парникових газів	Україна	Пересувні джерела	Всього викиди	Загалом	Річна	1436728	2020
2	210	Кількість викидів забруднюючих речовин і парникових газів	Україна	Стаціонарні джерела	Всього викиди	Загалом	Річна	2238628440	2020
3	211	Кількість викидів забруднюючих речовин і парникових газів	Вінницька	Пересувні джерела	Всього викиди	Загалом	Річна	51443	2020
4	212	Кількість викидів забруднюючих речовин і парникових газів	Вінницька	Стаціонарні джерела	Всього викиди	Загалом	Річна	78200	2020
5	213	Кількість викидів забруднюючих речовин і парникових газів	Волинська	Пересувні джерела	Всього викиди	Загалом	Річна	31669	2020
6	214	Кількість викидів забруднюючих речовин і парникових газів	Волинська	Стаціонарні джерела	Всього викиди	Загалом	Річна	5100	2020
7	215	Кількість викидів забруднюючих речовин і парникових газів	Дніпропетровська	Пересувні джерела	Всього викиди	Загалом	Річна	126006	2020
8	216	Кількість викидів забруднюючих речовин і парникових газів	Дніпропетровська	Стаціонарні джерела	Всього викиди	Загалом	Річна	534700	2020
9	217	Кількість викидів забруднюючих речовин і парникових газів	Донецька	Пересувні джерела	Всього викиди	Загалом	Річна	51491	2020
10	218	Кількість викидів забруднюючих речовин і парникових газів	Донецька	Стаціонарні джерела	Всього викиди	Загалом	Річна	751000	2020
11	219	Кількість викидів забруднюючих речовин і парникових газів	Житомирська	Пересувні джерела	Всього викиди	Загалом	Річна	42086	2020
12	220	Кількість викидів забруднюючих речовин і парникових газів	Житомирська	Стаціонарні джерела	Всього викиди	Загалом	Річна	11800	2020
13	221	Кількість викидів забруднюючих речовин і парникових газів	Закарпатська	Пересувні джерела	Всього викиди	Загалом	Річна	33326	2020
14	222	Кількість викидів забруднюючих речовин і парникових газів	Закарпатська	Стаціонарні джерела	Всього викиди	Загалом	Річна	3300	2020
15	223	Кількість викидів забруднюючих речовин і парникових газів	Запорізька	Пересувні джерела	Всього викиди	Загалом	Річна	71399	2020

Total rows: 104 Query complete 00:00:00.204 LF Ln 1, Col 35

Рисунок 3.3 – витяг записів з таблиці з інформацією про викиди забруднюючих речовин в атмосферне повітря

Query Query History

1

SELECT * FROM stage.population

2

ORDER BY id ASC

Data Output Messages Notifications

≡

📄

▼

📋

▼

🗑

📦

⬇

📈

SQL

	id [PK] integer	indicator character varying (255)	region_name character varying (255)	periodicity character varying (255)	population_count integer	year integer
1	1	Середня чисельність постійного населення	Україна	Річна	41575748	2020
2	2	Середня чисельність постійного населення	Вінницька	Річна	1530184	2020
3	3	Середня чисельність постійного населення	Волинська	Річна	1026681	2020
4	4	Середня чисельність постійного населення	Дніпропетровська	Річна	3156032	2020
5	5	Середня чисельність постійного населення	Донецька	Річна	4103159	2020
6	6	Середня чисельність постійного населення	Житомирська	Річна	1202622	2020
7	7	Середня чисельність постійного населення	Закарпатська	Річна	1249127	2020
8	8	Середня чисельність постійного населення	Запорізька	Річна	1676169	2020
9	9	Середня чисельність постійного населення	Івано-Франківська	Річна	1361877	2020
10	10	Середня чисельність постійного населення	Київська	Річна	1779008	2020
11	11	Середня чисельність постійного населення	Кіровоградська	Річна	920203	2020
12	12	Середня чисельність постійного населення	Луганська	Річна	2124020	2020
13	13	Середня чисельність постійного населення	Львівська	Річна	2486547	2020
14	14	Середня чисельність постійного населення	Миколаївська	Річна	1113413	2020
15	15	Середня чисельність постійного населення	Одеська	Річна	2361609	2020

Total rows: 52

Query complete 00:00:00.163

Рисунок 3.4 – витяг записів з таблиці з інформацією про населення

Перейдемо до імпорту даних з stage зони до main зони. Створимо 4 основні функції, що відповідатимуть за імпорт даних. Ми маємо три виміри та одну фактову таблицю. Заповнимо спочатку виміри – dim_region_data, dim_pollution, dim_year. На рисунку 3.5 зображено приклад функції, яка передбачає попередній витяг даних з відповідної таблиці main зони, їхнє порівняння з даними, які ми хочемо завантажити, та у разі виявлення відсутності дублікатів, відбувається імпорт даних.

```
def load_dim_region_data():
    query = "SELECT DISTINCT region_name FROM stage.population WHERE region_name IS NOT NULL"
    df_regions = pd.read_sql(query, engine)

    query_existing = "SELECT region_name FROM main.dim_region_data"
    df_existing = pd.read_sql(query_existing, engine)

    df_new = df_regions.merge(df_existing, on='region_name', how='left', indicator=True)
    df_new = df_new[df_new['_merge'] == 'left_only'][['region_name']]

    if not df_new.empty:
        df_new.to_sql('dim_region_data', schema='main', con=engine, if_exists='append', index=False)
        print(f"Додано {len(df_new)} нових регіонів до main.dim_region_data.")
    else:
        print("Нових регіонів для додавання немає.")

load_dim_region_data()
```

Рисунок 3.5 – функція для імпорту даних у таблицю main зони.

За відповідною аналогією та створеними функціями, які будуть наведені у Додатку, ми реалізуємо імпорт даних до main зони. На рисунках 3.5 – 3.8 зображено витяг даних з кожної таблиці main зони.

Query

Query History

1

SELECT * FROM main.cancer_analysis

2

ORDER BY id ASC

Data Output

Messages

Notifications

SQL

Showing rows: 1 to 104

	id [PK] integer	region_info integer	population_count integer	year_info integer	death_cases_count integer	disease_cases_count integer	crude_death_rate numeric (5,2)	crude_disease_rate numeric (5,2)	pollution_info integer	pollution_count numeric (20,2)
1	625	33	41575748	4	56980	109409	151.30	291.00	4	1436728.00
2	626	33	41575748	4	56980	109409	151.30	291.00	3	2238628440.00
3	627	49	1530184	4	2466	4361	160.30	283.60	4	51443.00
4	628	49	1530184	4	2466	4361	160.30	283.60	3	78200.00
5	629	42	1026681	4	1573	2585	152.90	251.30	4	31669.00
6	630	42	1026681	4	1573	2585	152.90	251.30	3	5100.00
7	631	52	3156032	4	3937	9715	124.10	306.10	4	126006.00
8	632	52	3156032	4	3937	9715	124.10	306.10	3	534700.00
9	633	45	4103159	4	2235	4168	54.50	101.60	4	51491.00
10	634	45	4103159	4	2235	4168	54.50	101.60	3	751000.00
11	635	48	1202622	4	1651	3106	136.60	256.90	4	42086.00
12	636	48	1202622	4	1651	3106	136.60	256.90	3	11800.00
13	637	51	1249127	4	1287	2294	102.90	183.40	4	33326.00
14	638	51	1249127	4	1287	2294	102.90	183.40	3	3300.00
15	639	46	1676169	4	2801	5139	166.10	304.70	4	71399.00

Total rows: 104

Query complete 00:00:00.122

Рисунок 3.5 – витяг даних фактової таблиці cancer_analysis

QueryQuery History

1 SELECT * FROM main.dim_pollution

2 ORDER BY pollution_id ASC

Data OutputMessagesNotifications

SQL

	pollution_id [PK] integer	source_name character varying (255)	category_name character varying (255)	pollutant_type_name character varying (255)
1	3	Стационарні джерела	Загалом	Всього викиди
2	4	Пересувні джерела	Загалом	Всього викиди

Рисунок 3.6 – витяг даних з таблиці виміру dim_pollution

QueryQuery History

1 SELECT * FROM main.dim_region_data

2 ORDER BY region_id ASC

Data OutputMessagesNotifications

SQL

	region_id [PK] integer	region_name character varying (255)
1	27	Луганська
2	28	Харківська
3	29	Миколаївська
4	30	Хмельницька
5	31	Тернопільська
6	32	Черкаська
7	33	Україна
8	34	Чернігівська
9	35	Сумська
10	36	Полтавська
11	37	Івано-Франківська
12	38	Київ
13	39	Чернівецька
14	40	Херсонська
15	41	Київська

Total rows: 26

Query complete 00:00:00.122

Рисунок 3.7 – витяг даних з таблиці виміру dim_region_data

Query		Query History	
1	SELECT *	FROM	main.dim_year
2	ORDER BY	year_id	ASC

Data Output		Messages		Notifications	
+	SQL				
	year_id		year		
	[PK] integer		integer		
1		3	2021		
2		4	2020		

Рисунок 3.8 – витяг даних з таблиці виміру dim_year

3.3 Розподіл даних

Зчитуємо наші дані з фактової таблиці в датафрейм, над яким згодом будемо проводити аналіз. Помічаємо, що для кращого аналізу даних зручно частково транспонувати деякі стовпці. Попердньо у одному записі ми маємо ознаку “джерело забруднення” – це або стаціонарне або пересувне у нашому випадку. Та і відповідно кількість викидів від цих джерел. Створимо дві нові колонки – `mobile_pollution` та `stationary_pollution`, які міститимуть інформацію про кількість своїх викидів відповідно. На рисунку 3.9 зображено перші 10 записів нашого датафрейму вже після зміни колонок.

source_name	region_name	year	death_cases_count	disease_cases_count	crude_death_rate	crude_disease_rate	population_count	mobile_pollution	stationary_pollution
0	Івано-Франківська	2020	2135	3575	156.4	261.8	1361877	33090.0	140400.0
1	Івано-Франківська	2021	2084	4135	153.4	304.4	1353740	37904.0	172400.0
2	Волинська	2020	1573	2585	152.9	251.3	1026681	31669.0	5100.0
3	Волинська	2021	1445	2897	141.0	282.7	1021648	30821.0	5600.0
4	Вінницька	2020	2466	4361	160.3	283.6	1530184	51443.0	78200.0
5	Вінницька	2021	2314	4600	152.0	302.2	1512234	55155.0	79300.0
6	Дніпропетровська	2020	3937	9715	124.1	306.1	3156032	126006.0	534700.0
7	Дніпропетровська	2021	4034	10242	128.5	326.3	3115951	133461.0	537600.0
8	Донецька	2020	2235	4168	54.5	101.6	4103159	51491.0	751000.0
9	Донецька	2021	3058	6534	75.2	160.7	4066941	51334.0	744100.0

Рисунок 3.9 – перші 10 записів датасету.

Розподілимо наші дані на декілька вибірок за різними ознаками, кожна міститиме в собі тренувальний та навчальний набір (рис. 3.10)

```
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2)
print("Number of test samples: ", x_test.shape[0])
print("Number of training samples: ", x_train.shape[0])
```

✓ 0.0s

Number of test samples: 10
Number of training samples: 40

Рисунок 3.10 – розподілена вибірка даних

Оскільки у нас присутні такі показники як кількість смертей та захворювань на 100 тис. осіб, доцільно порахувати нові – кількість викидів забруднюючих речовин на 100 тис. населення, задля майбутнього дослідження взаємозв'язку між цими ознаками. На рисунку 3.11 зображено код для обрахунку відповідних показників та додавання їх до нашого датафрейму.

```

df['mp_rate'] = 0; #mobile pollution per 100k of population
df['sp_rate'] = 0; #stationary pollution per 100k of population

df = df.astype({"mp_rate": "float", "sp_rate": "float"})

def count_rates(column1, column2, new_column):
    for index, row in df.iterrows():
        value1 = row[column1]
        value2 = row[column2]
        rate = value1 * 100000 / value2
        df.at[index, new_column] = round(rate, 2)

```

✓ 0.0s

```

df.dtypes

```

```

count_rates('mobile_pollution', 'population_count', 'mp_rate')

```

✓ 0.0s

```

count_rates('stationary_pollution', 'population_count', 'sp_rate')

```

✓ 0.0s

Рисунок 3.10 – Обрахунок нових показників mp_rate та sp_rate

4.ІНТЕЛЕКТУАЛЬНИЙ АНАЛІЗ ДАНИХ

4.1 Обґрунтування вибору методів інтелектуального аналізу даних

Для дослідження взаємозв'язку між ознаками необхідно використовувати інтелектуальний аналіз даних. В даній курсовій роботі передбачено кореляційний аналіз, щоб дослідити зв'язки між змінними. Кореляційним аналізом називають сукупність методів виявлення кореляційного зв'язку. Тому його можна застосувати для формалізованого подання моделей зв'язків між окремими компонентами системи або між окремими процесами, що відбуваються в ній. [6] Цей метод було обрано, тому що це допомагає ідентифікувати потенційні фактори, що впливають на цільові показники (до прикладу, зв'язок між забрудненням та захворюванням). Використання теплової карти для представлення результатів забезпечує наочну інтерпретацію результатів.

Також прийнято рішення побудувати моделі Лінійної регресії, оскільки лінійна регресія є базовим методом інтелектуального аналізу, який добре підходить для початкового дослідження зв'язків між змінними. Цей метод є простим, швидким і дозволяє оцінити силу та напрямок зв'язків. Однак він є менш ефективним для нелінійних залежностей. Для розширення лінійної регресії також обрано модель поліноміальної регресії, оскільки вона дозволяє моделювати нелінійні залежності шляхом додавання поліноміальних членів, виявляючи складніші закономірності в даних, коли лінійна модель недостатньо точна.

Кластерний аналіз є частиною інтелектуального аналізу даних, оскільки він спрямований на виявлення закономірностей і групування даних для подальшого аналізу. Обраний метод K-Means обраний для групування регіонів за рівнем викидів забруднюючих речовин та показниками захворюваності та смертності від раку. Це корисно для виявлення закономірностей, таких як регіони з високим забрудненням і високою захворюваністю, без необхідності прогнозувати конкретні значення.

4.2 Аналіз отриманих результатів дослідження кореляції між ознаками

Побудуємо теплову карту кореляцій між кількісними ознаками, враховуючи дані за 2020 рік (рис. 4.1)




Рисунок 4.1 – теплова карта кореляцій між кількісними ознаками за 2020 рік

Бачимо, що такі ознаки як кількість випадків захворювання та кількість випадків смертей мають сильну позитивну кореляцію з такою ознакою, як кількість викидів з пересувних джерел, та слабку позитивну кореляцію з такою ознакою, як кількість викидів з стаціонарних джерел. Якщо порівнювати з грубими показниками захворюваності та смертності, то вони мають негативний зв'язок з такою ознакою, як викиди зі стаціонарних джерел. Побудуємо таку ж карту кореляцій, але за 2021 рік (рис. 4.2).




Рисунок 4.2 - теплова карта кореляцій між кількісними ознаками за 2021 рік

Спостерігаємо таку ж саму картину. Несподівано, але стаціонарне забруднення (заводи, цехи, фабрики) має слабкий негативний зв'язок із онкологічними показниками. Це може свідчити про те, що стаціонарні джерела забруднення не є основним фактором впливу на здоров'я цих даних. Пересувне забруднення (автомобільні викиди) має сильніший зв'язок із кількістю випадків захворювання та смертей, ніж стаціонарне, що може вказувати на пріоритетність цього фактора для подальшого аналізу.

Врахуємо обраховані нами показники “кількість викидів на 100 тис. населення” та проаналізуємо, чи корелюють вони з такими показниками, як грубий показник захворюваності (смертності) на 100 тис. населення (рис. 4.3). Знову ж, порівняємо дані за 2020 та 2021 роки.




Рисунок 4.3 – Теплова карта кореляцій між доданими ознаками за 2020 рік

Бачимо, що *mp_rate* (пересувні джерела на 100 тис. осіб) помірно корелює з такою ознакою як грубий показник захворюваності на 100 тис. осіб. Проте він слабше корелює з такою ознакою як грубий показник смертності на 100 тис. осіб. Показник *sp_rate* (стаціонарні джерела на 100 тис. осіб) негативно корелює з обома грубими показниками. Таку ж саму картину ми спостерігали, коли робили висновок про те, що викиди стаціонарних джерел слабко корелюють з кількостями захворювань та смертей. Теплова карта кореляцій за 2021 рік описує таку ж саму ситуацію (рис. 4.4)




Рисунок 4.4 - Теплова карта кореляцій між доданими ознаками за 2021 рік

Обрахуємо коефіцієнт кореляції Пірсона та p-value для обраних потенційних ознак за 2020 рік (рис. 4.5)

```
death_cases_count VS mobile_pollution
Pearson: 0.80051
P-value: 1.5485e-06
disease_cases_count VS mobile_pollution
Pearson: 0.87182
P-value: 1.3852e-08
population_count VS mobile_pollution
Pearson: 0.58793
P-value: 0.0019966
```

Рисунок 4.5 – обраховані коефіцієнти кореляції Пірсона та з p-value

Кількість захворювань сильно корелює з викидів пересувних джерел, а p -value вказує, що кореляція є статистично значущою. Аналізуючи ці ж самі ознаки, але за 2021 рік, ситуація є схожою – коефіцієнт кореляції Пірсона для ознак кількості викидів зі пересувних джерел та кількості смертей становить 0,76, для кількості захворювань – 0,85. P -value в обох випадках менше за 0,05.

Будуємо діаграми розсіювання (рис. 4.6)




Рисунок 4.6 – Діаграми розсіювання, викиди з пересувних джерел

Знову ж таки, поглянемо на залежність між викидами пересувних джерел та кількістю захворювань та смертей. Існує позитивний зв'язок між цими ознаками. Лінія регресії має додатний нахил, а точки даних загалом узгоджуються з цією тенденцією. Вищий рівень забруднення від пересувних джерел корелює зі збільшенням кількості смертей від раку. Це підтверджує попередній кореляційний аналіз, вказуючи потенційний вплив забруднення на смертність та захворюваність.

Поглянемо тепер на залежність з кількостями забруднюючих викидів зі стаціонарних джерел. Побудуємо діаграми розсіювання (рис. 4.7)




Рисунок 4.7 – Діаграми розсіювання, викиди зі стаціонарних джерел

Є слабкий позитивний зв'язок між кількістю смертей і захворювань, та кількістю викидів від стаціонарного забруднення. Лінія регресії має невеликий додатний нахил, але точки даних сильно розкидані, і кореляція виглядає слабкою. Це ще раз доводить, що вплив стаціонарного забруднення на кількість смертей та захворювань на рак є обмеженим. Це узгоджується з кореляцією, що становить 0,28, що вказує на слабкий зв'язок.

Попередньо робимо висновок, що цільовими ознаками, які ми досліджуватимемо далі є кількість захворювань та смертей, кількість викидів зі пересувних джерел та показники смертності, захворюваності, викидів з пересувних джерел на 100 тис. населення. Побудуємо додатковий комбінований графік гістограми та лінійного графіку, в якому відобразимо дані за регіонами. Гістограма показує кількість випадків захворювання на рак для кожного регіону, а лінійний графік відображає рівень пересувного забруднення для тих же регіонів. (рис. 4.8)




Рисунок 4.8 – Комбінований графік гістограми та лінійного графіку

Загалом, форма графіку показує, що регіони з вищим рівнем пересувного забруднення мають тенденцію до більшої кількості випадків захворювання, хоча кореляція не є ідеальною (деякі точки відхиляються від загальної тенденції). Піки на лінії забруднення (наприклад, Івано-Франківська, Дніпропетровська) збігаються з піками захворюваності, що підкреслює зв'язок між цими змінними.

Пересувне забруднення здається важливим фактором, що впливає на кількість випадків захворювання та смертей, особливо в регіонах з високим значенням обох показників (Івано-Франківська, Дніпропетровська).

4.3 Аналіз отриманих результатів кластеризації

Проведемо кластерний аналіз та дослідимо розподіл регіонів за двома ознаками: кількість випадків захворювань на рак та кількість викидів від пересувного забруднення. Спочатку оберемо оптимальну кількість кластерів з допомогою метода ліктя. З рисунку 4.9 бачимо, що оптимальна кількість – 3.




Рисунок 4.9 – Дослідження оптимальної кількості кластерів методом ліктя

За допомогою кластеризації методом k-середніх, який ми використовуємо з бібліотеки sklearn отримуємо наступні результати (рис. 4.10)




Рисунок. 4.10 – Результат кластеризації

У жовтий кластер потрапили регіони, що мають низький рівень захворюваності та забруднення. Це такі регіони як Волинська, Тернопільська,

Рівненська, Чернівецька області. У фіолетовий кластер потрапили регіони з помірним рівнем забруднення та захворюваності. Це такі області як Вінницька, Запорізька, Київська, Львівська, Одеська, Полтавська. І у зелений кластер потрапили регіони з високим рівнем захворюваності та забруднення, такі як Дніпропетровська, Харківська області та м. Київ.

Знову ж таки є позитивна тенденція: регіони з більшою кількістю викидів з пересувних джерел мають тенденцію до вищої кількості захворювань на рак. Розподіл точок показує, що кластери добре відокремлюють регіони за цими ознаками. Цей аналіз краще сегментує регіони за рівнем ризику, виділяючи зону з екстримально високими значеннями (зелений кластер), що корисно для цільових заходів, наприклад, зменшення забруднення в Дніпропетровській, Харківській області та в м. Київ. Регіони з зеленим кластером потребують пріоритетної уваги в екологічній політиці, тоді як жовтий кластер може слугувати еталоном для менш забруднених зон. Отримані результати є корисними для стратегічного планування та подальшого прогнозного моделювання.

4.4 Аналіз моделі Linear Regression

З допомогою бібліотеки `sklearn` створимо модель `LinearRegression()`, навчимо та протестуємо її з допомогою навчальних та тренувальних даних, що зробили ми раніше. Отримуємо наступні результати продуктивності моделі (рис. 4.11)



```

> print('R^2 with train data: ', model.score(x_train[['mobile_pollution']], y_train))
> print('R^2 with test data: ', model.score(x_test[['mobile_pollution']], y_test))

[168] ✓ 0.0s
... R^2 with train data: 0.7337829668834832
    R^2 with test data: 0.7587344584559328
  
```


Рисунок 4.11 – Отримані результати R^2

R^2 на тренувальній вибірці 0,7338 означає, що модель пояснює приблизно 73,4% варіації ознаки кількості захворювань на основі кількості викидів забруднюючих речовин з пересувних джерел у тренувальних даних. R^2 на

тестовій вибірці вказує на те, що модель пояснює приблизно 75,9% варіації у тестових даних. Значення R^2 є досить високим, що свідчить про хорошу пояснювальну здатність зв'язку між досліджуваними ознаками. Факт, що R^2 на тестовій вибірці трохи вищий, ніж на тренувальній, є позитивним сигналом, оскільки це вказує на відсутність перенавчання і на те, що модель добре узагальнює на нових даних.

Модель демонструє стабільну продуктивність на тренувальних і тестових даних, що є хорошим знаком. Однак, через невеликий розмір тестової вибірки результати можуть бути чутливими до конкретного розподілу даних.

Використаємо крос-валідацію для кращої оцінки, отримуємо наступні результати (рис. 4.12)



```

> from sklearn.model_selection import cross_val_score
  scores = cross_val_score(model1, x[['mobile_pollution']], y, cv=5)
  print("Mean CV R²:", scores.mean())

[224] ✓ 0.0s

... Mean CV R²: 0.47030900413352583

```

Рисунок 4.12 – результат крос-валідаційного тесту

Це значення відображає середню пояснювальну здатність моделі лінійної регресії на різних підмножинах даних. Отриманий результат свідчить про те, що модель менш стабільна при перевірці на різних підмножинах даних, ніж на одному конкретному розбитті.

Слід зазначити, що високі R^2 на одному розбитті можуть бути результатом випадкового вдалого розподілу даних, тоді як крос-валідація показує більш реалістичну оцінку продуктивності моделі. У нашому випадку невеликий розмір набору даних може призводити до значних коливань у продуктивності моделі залежно від того, які дані потрапляють у тренувальну чи тестову вибірку.

Підводячи проміжний підсумок, можна стверджувати, що модель лінійної регресії має помірну пояснювальну здатність, але не є оптимальною для наших даних. Нижчий результат крос-валідації порівняно з R^2 на тренувальній і тестових вибірках вказує на нестабільність моделі через невеликий розмір даних або можливі нелінійні зв'язки.

4.5 Аналіз поліноміальної моделі лінійної регресії

Спочатку визначимо оптимальний порядок полінома (рис. 4.13)




Рисунок 4.13 – Отримання оптимального порядку полінома

З результатів бачимо, що оптимальним є 2-ий порядок полінома, тому що подальше збільшення порядку не дає користі, а скоріше погіршує узагальнення, що є типовим для невеликих наборів даних, де високі ступені полінома можуть призводити до перенавчання. Побудуємо модель полінома 2 порядку та визначимо значення R^2 (рис. 4.14)

```

pr1 = PolynomialFeatures(degree=2)
x_train_pr1 = pr1.fit_transform(x_train[['mobile_pollution']])
x_test_pr1 = pr1.transform(x_test[['mobile_pollution']])
model3 = LinearRegression()
model3.fit(x_train_pr1, y_train)
y_test_predicted1 = model3.predict(x_test_pr1)

[237] ✓ 0.0s

r2 = r2_score(y_test, y_test_predicted1)
print('R^2: ', r2)

[238] ✓ 0.0s
... R^2: 0.7834183431773611

```

Рисунок 4.14 – Отримані результати поліноміальної моделі

Проведемо крос-валідаційний тест та отримуємо наступні результати (рис. 4.15)

```

x_poly = pr1.fit_transform(x[['mobile_pollution']])

[239] ✓ 0.0s

cv_scores = cross_val_score(model3, x_poly, y, cv=5, scoring='r2')

[240] ✓ 0.0s

print("Mean CV R^2 for degree 2:", cv_scores.mean())

[241] ✓ 0.0s
... Mean CV R^2 for degree 2: 0.49563810961925936

```

Рисунок 4.15 – Крос-валідаційний тест для поліноміальної моделі 2 порядку.

ВИСНОВКИ

В результаті виконання курсової роботи було розроблено сховище даних типу “зірка” для зберігання інформації про онкозахворювання та викиди забруднюючих речовин. Сховище даних складається з двох схем – stage та main зони. Вхідні дані було оброблено, завантажено до stage зони та до main відповідно за допомогою Python бібліотек pandas та sqlalchemy та СУБД PostgreSQL.

Проведено інтелектуальний аналіз даних – досліджено кореляцію між ознаками, побудовано теплові карти для кращої візуалізації кореляції між ознаками. Визначено, що найбільше корелюють між собою ознаки “кількість захворювань” та “викиди з пересувних джерел”. Про це свідчить коефіцієнт кореляції Пірсона – 0,87 та p-value – 1,38e-08, що свідчить про те, що кореляція є статистично значущою. Водночас, кореляція між такими ознаками як “кількість захворювань”, “кількість смертей” та “викиди зі стаціонарних джерел” є слабкою – коефіцієнт кореляції Пірсона показав 0,28, а p-value дорівнює 0,17. Кореляція між такими ознаками як “населення” та “викиди з стаціонарних джерел” показала значення 0,77, що виглядає логічним, оскільки більш індустріальні регіони мають більшу кількість населення.

Проведено кластерний аналіз, за допомогою методу “ліктя” обрано оптимальну кількість кластерів – 3, що дозволило нам згрупувати регіони за низькою, помірною, та високою кількістю захворювань на рак та кількістю викидів зі стаціонарних джерел. Це несе користь для визначення пріоритетних регіонів для дій, до прикладу сконцентрувати ресурси держави чи місцевої влади на регіонах із високим рівнем захворюваності та викидів, а також для формування регіональної екологічної політики, а саме адаптувати стратегії боротьби з онкозахворюваннями відповідно до групи регіону.

Створено модель лінійної регресії, яку було навчено та протестовано навчальним та тренувальним набором даних. R^2 на тестовій вибірці показав, що модель пояснює приблизно 75,9% варіації у тестових даних. Під час проведення

крос-валідаційного тесту, отримали середній результат 0,47 – це значення відображає середню пояснювальну здатність моделі лінійної регресії на різних підмножинах даних. Отриманий результат свідчить про те, що модель менш стабільна при перевірці на різних підмножинах даних, ніж на одному конкретному розбитті. Нижчий результат крос-валідації порівняно з R^2 на тренувальній і тестовій вибірках вказує на нестабільність моделі через невеликий розмір даних або можливі нелінійні зв'язки.

Створено модель поліноміальної лінійної регресії, попередньо визначивши оптимальний порядок полінома – 2ий. Подальше збільшення порядку не давало користі, а скоріше погіршувало узагальнення, що є типовим для невеликих наборів даних, де високі ступені полінома можуть призводити до перенавчання. R^2 показав результат 0,78, а крос-валідаційний тест – 0,49, що як і у випадку моделі лінійної регресії вказує на слабку здатність моделі узагальнювати на нові, невідомі дані.

Порівнюючи результати обох моделей, можна зробити висновок, що модель лінійної регресії має низьку стабільність, помірну схильність до перенавчання. Поліноміальна модель лінійної регресії має трішки вищу стабільність порівняно з моделлю лінійної регресії, але також низьку стабільність, а щодо схильності до перенавчання – має вищу схильність, оскільки це є типовим для поліномів. Обидві моделі мають нестабільні результати на крос-валідації – це сигнал про можливу перенавченість або недостатню кількість даних. Поліноміальна модель трохи краще вчиться (має вищий R^2), але не демонструє значно кращого узагальнення, тому її складність не виправдана. Обидві моделі мають обмежену пояснювальну здатність описувати залежність між кількістю захворювань та викидами з пересувних джерел – навіть краща з них, поліноміальна модель, узагальнює лише приблизно 49% варіації на нових даних.

Отримані результати можуть свідчити про обмежену роль лише цього одного чинника – кількості викидів з пересувних джерел. Ймовірно, кількість

захворювань залежить також від інших факторів, які не враховані у поточному аналізі, до прикладу соціально-економічні умови, доступ до медицини, тощо.

Перспективи подальших досліджень полягають у розширенні обсягу вхідних даних та включені моделі додаткових факторів, які можуть впливати на рівень онкозахворювань у регіонах України. Зокрема доцільно врахувати соціально-економічні показники, доступність медичних послуг, рівень урбанізації та інші екологічні чинники. Крім того, подальше дослідження може передбачати застосування більш складних методів машинного навчання та підвищення точності прогнозування та оцінки взаємозв'язків між змінними.

ПЕРЕЛІК ПОСИЛАНЬ

1. Захворюваність на рак в Україні. URL: <https://www.radiosvoboda.org/a/2297337.html> (дата звернення: 25.05.2025)
2. Атмосферні канцерогени та рак під час війни в Україні. URL: <https://health-ua.com/onkologiya-i-gematologiya/onkologiya/72757-atmosfern-kantserogeni-tarak-pdchas-vjni-vukran> (дата звернення: 25.05.2025)
3. Що відноситься до стаціонарних джерел забруднення атмосфери? URL: <https://od.tax.gov.ua/media-ark/news-ark/615632.html> (дата звернення: 25.05.2025)
4. Джерела забруднення атмосферного повітря. URL: <https://ecolog-ua.com/news/dzherela-zabrudnennya-atmosfernogo-povitrya> (дата звернення: 25.05.2025)
5. Аналіз впливу факторів. URL: https://docs.google.com/document/d/1sKD0l-NKm_EuR8XCXGXO6-br7avzv2i-dTm0IL74D30/edit?tab=t.0#heading=h.mxdjzn639vhn (дата звернення: 26.05.2025)

ДОДАТОК А ТЕКСТИ ПРОГРАМНОГО КОДУ

*Тексти програмного коду дослідження впливу викидів
забруднюючих речовин на онкозахворювання в регіонах
України*

(Найменування програми (документа))

Github репозиторій

(Вид носія даних)

<https://github.com/saszco/courseWorkDA>

Посилання

студента групи ІП-33 ІІ курсу

Корольчука Олександра Сергійовича